

Algorithmen und Wahrscheinlichkeit

Woche 9

Ilya Maier

Abschätzen von Wahrscheinlichkeiten

Markovs Ungleichung:

$$\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t} \quad \forall X \geq 0, \forall t > 0, t \in \mathbb{R}$$

Chebyshevs Ungleichung:

$$\Pr[|X - \mathbb{E}[X]| \geq t] \leq \frac{\text{Var}[X]}{t^2} \quad \forall X, \forall t > 0, t \in \mathbb{R}$$

Ist nun Markov oder Chebyshev besser?

$$\Pr[X \geq t] \leq \Pr[X - \mathbb{E}[X] \geq t - \mathbb{E}[X]] \leq \Pr[|X - \mathbb{E}[X]| \geq t - \mathbb{E}[X]] \leq \frac{\text{Var}[X]}{(t - \mathbb{E}[X])^2}$$

d.h. $t > \mathbb{E}[X]$, also WLOG sei $t = \mathbb{E}[X] + k \cdot \sqrt{\text{Var}[X]}$ für $k > 0$

dann $\frac{\text{Var}[X]}{(t - \mathbb{E}[X])^2} = \frac{\text{Var}[X]}{k^2 \text{Var}[X]} = \frac{1}{k^2}$, wenn also $k^2 \mathbb{E}[X] > \mathbb{E}[X] + k\sqrt{\text{Var}[X]}$ ist, dann ist Chebyshev besser

Abschätzen von Wahrscheinlichkeiten

Chernoffs Ungleichung:

1. $\Pr[X \geq (1 + \delta)\mathbb{E}[X]] \leq e^{-\frac{1}{3}\delta^2\mathbb{E}[X]}$
 2. $\Pr[X \leq (1 - \delta)\mathbb{E}[X]] \leq e^{-\frac{1}{2}\delta^2\mathbb{E}[X]}$
- $\forall X \sim \text{Bin}(n, p)$
 $\forall 0 < \delta \leq 1$

Korollar:

1. $\Pr[X - \mathbb{E}[X] \geq \delta\mathbb{E}[X]] \leq e^{-\frac{1}{3}\delta^2\mathbb{E}[X]}$
2. $\Pr[X - \mathbb{E}[X] \leq -\delta\mathbb{E}[X]] \leq e^{-\frac{1}{2}\delta^2\mathbb{E}[X]}$
3. $\Pr[|X - \mathbb{E}[X]| \geq \delta\mathbb{E}[X]] \leq e^{-\frac{1}{3}\delta^2\mathbb{E}[X]} + e^{-\frac{1}{2}\delta^2\mathbb{E}[X]} \leq 2e^{-\frac{1}{3}\delta^2\mathbb{E}[X]}$

Target Shooting

Gegeben: endliche Mengen S, U s.d. $S \subseteq U$,

$$I_S : U \rightarrow \{0,1\} : I_S(u) = 1 \iff u \in S$$

Gesucht: $|S|/|U|$

Algorithmus

1) wähle u_1, \dots, u_N aus U zufällig unabhängig und gleichverteilt

$$2) \text{ return } Y := \frac{1}{N} \sum_{i=1}^N I_S(u_i) \quad \implies \quad \mathbb{E}[Y] = \frac{|S|}{|U|}$$

Satz: (geeignetes N finden)

Für $\delta, \epsilon > 0$:

$$N \geq 3 \frac{|U|}{|S|} \epsilon^{-2} \ln \left(\frac{2}{\delta} \right) \quad \implies \quad \Pr \left[|Y - \mathbb{E}[Y]| \geq \epsilon \cdot \mathbb{E}[Y] \right] \leq \delta$$

(Kann man mit Chernoffs Ungleichungen i) und ii) zeigen)

Primzahltest

A. GGT

$\gcd(a, n) > 1$ für $1 \leq a \leq n - 1$
 $\implies n$ nicht prim

i) “nicht prim” immer richtig

$$\text{ii) } \Pr[\text{"prim"} \mid \text{nicht prim}] = \frac{|Z_n^*|}{n - 1}$$

$$\text{iii) } \text{cost}(\gcd(m, n)) = \mathcal{O}((\log nm)^3)$$

B. Fermat's little theorem

n ist prim
 $\implies \forall a \in [n - 1] : a^{n-1} \equiv 1 \pmod n$

i) “nicht prim” immer richtig

$$\text{ii) } \Pr[\text{"prim"} \mid \text{nicht prim}] = \frac{|PB_n|}{n - 1}$$

$$\text{iii) } PB_n := \{a \in \mathbb{Z}_n^* \mid a^{n-1} \equiv 1 \pmod n\}$$

iv) Carmichael-Zahl n :

1) n ist nicht prim

$$2) PB_n = \mathbb{Z}_n^*$$

$$\text{v) } \Pr[\text{"prim"} \mid \text{nicht prim}] < 0.5,$$

falls n nicht Carmichael

\implies Verbesserung durch Wiederholung

C. Miller-Rabin

Miller-Rabin-PrimeTest(n)

- 1) Wähle $1 \leq a \leq n - 1$ gleichverteilt zufällig
- 2) $d, k \in \mathbb{N}$ s.d. $n - 1 = 2^k d$, wobei d ungerade
- 3) **if** $a^d \pmod n \neq 1$ **&&**
 $\nexists i < k : a^{2^i d} \pmod n = n - 1$ **then**
 return “nicht prim”
- 4) **else return** “prim”

i) “nicht prim” immer richtig

$$\text{ii) } \Pr[\text{"prim"} \mid \text{nicht prim}] \leq \frac{1}{4}$$

\implies Verbesserung durch Wiederholung

iii) Laufzeit: $\mathcal{O}(\text{poly}(\log n))$

Duplikate finden

Datenmenge: $S = (s_1, \dots, s_n)$, ggf. so, dass jeder s_i sehr viel Speicherplatz braucht (viel mehr als Integer)

Duplikate: (i, j) wobei $1 \leq i < j \leq n$, falls $s_i = s_j$

A. Sortieren

- 1) Sortiere $((s_i, i))_{1 \leq i \leq n}$ nach s_i
- 2) Iteriere und finde Duplikate

- i) Sortieren: $\mathcal{O}(n \log n)$
- ii) Iterieren: $\mathcal{O}(n + |\text{Dupl}(S)|)$

B. Hashing

- 1) Hashe S mit $h : S \rightarrow [m]$
$$\Pr[h(s) = i] = \frac{1}{m}$$

- 2) Sortieren
- 3) Iterieren

- i) Hashen: $\mathcal{O}(n)$
- ii) Sortieren: $\mathcal{O}(n \log n)$
- iii) Iterieren: $\mathcal{O}(n + |\text{Dupl}(S)| + \#\text{Kollisionen})$

Kollisionen: (i, j) , wobei $s_i \neq s_j \wedge h(s_i) = h(s_j)$

$$\mathbb{E}[\#\text{Kollisionen}] \leq \binom{n}{2} \frac{1}{m}$$

C. Bloom Filter

- 1) Hashe S mit k Hashfunktionen $h_i : S \rightarrow [m]$
- 2) Wenn alle $h_i(s_j)$ Werte vorgekommen sind
fügen wir s_j in L hinzu.

- i) Hashen: $\mathcal{O}(kn)$
- ii) Iteration: $\mathcal{O}(n + n \cdot |L|)$

$\mathbb{E}[\#\text{falsche } L\text{-Einträge}]$

$$\leq n \left(1 - \left(1 - \frac{1}{m} \right)^{k(n-1)} \right)^k$$

Kahoot

Aufgaben